NEXIALOG CONSULTING

Journée scientifique : IA & Risque de crédit

Intégration du Machine Learning et du Risque Climatique dans la Tarification du Crédit-Bail

Armand L'HUILLIER

09 / 01 / 2026

THINK SMART ACT DIFFERENT

Sommaire

Intégration du Machine Learning et du Risque Climatique dans la Tarification du Crédit-Bail

- **Introduction au crédit-bail**
- Modélisation classique
- Intégration du Machine Learning
- Intégration du risque climatique

Introduction
Crédit-bail

Le crédit-bail (« leasing » en anglais) est un contrat de location d'un bien. Il permet à un tier d'utiliser un bien sans l'acheter immédiatement, en payant des loyers réguliers pendant une durée déterminée.

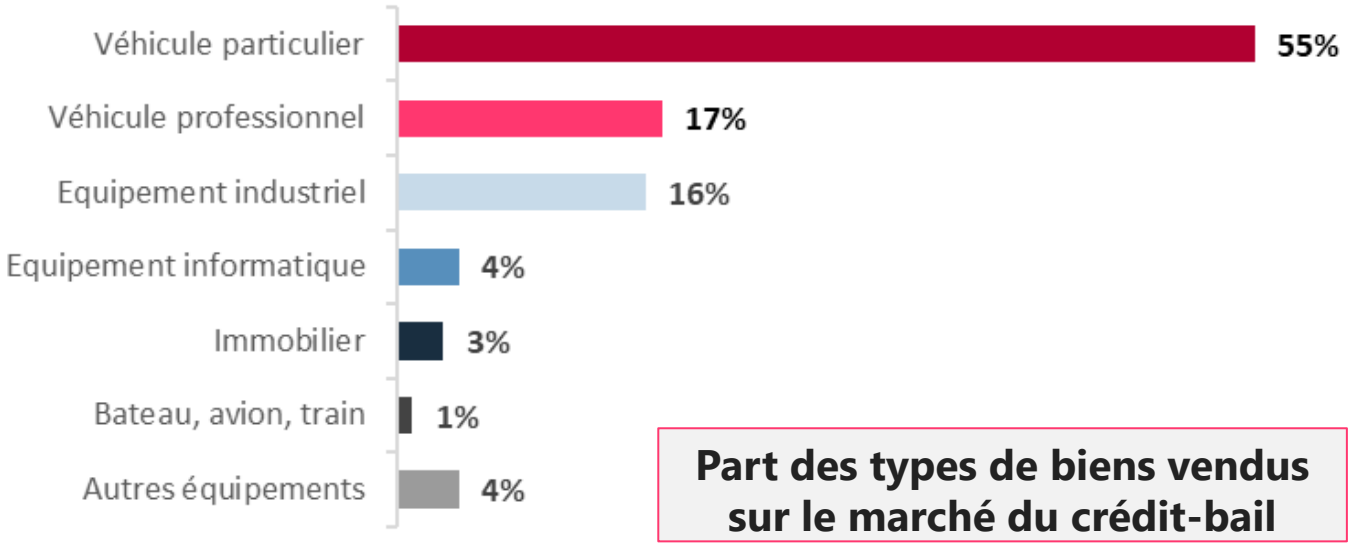

Part des types de biens vendus sur le marché du crédit-bail

La location de véhicules pris de l'importance dans les années 1950 aux États-Unis, avant de traverser l'Atlantique dans les années 1960. La Location Longue Durée (LLD) et la Location avec Option d'Achat (LOA) ont séduit les entreprises dans les années 80 et 90 pour des raisons fiscales et comptables. En 2021, 82 % des véhicules neufs étaient financés par leasing chez les professionnels.

Interactions entre les acteurs du secteur

Introduction

Typologie des contrats

Location longue durée (LLD)	Location avec option d'achat (LOA)
Ce type de location convient à ceux qui préfèrent ne pas devenir propriétaires du bien. Une société spécialisée achète le bien à un constructeur et en devient propriétaire. La société spécialisée loue ensuite au particulier ou à l'entreprise, qui paie un **loyer mensuel** et utilise le bien selon les conditions du contrat. **À la fin de la période de location, le bien doit être restitué** à la société de leasing sans possibilité d'achat. Le contrat de LLD définit la durée de location, les conditions d'utilisation, et les coûts associés, qui peuvent inclure l'entretien, les réparations et l'assurance. En cas de non-respect des conditions d'utilisation ou de défaut de paiement, des pénalités peuvent être appliquées, et le bien peut être récupéré par le loueur. Un dépôt de garantie peut être exigé, remboursable à la fin du contrat sous réserve de l'état du bien.	Location avec promesse de vente, une forme de crédit à la consommation destinée à l'acquisition temporaire ou permanente d'un bien. **A l'issue de la période de location de la LOA, le locataire dispose de trois options :** • **Restituer le bien et éventuellement signer un nouveau contrat de LOA.** • **Devenir propriétaire en payant le solde de la valeur résiduelle du contrat.** • **Revendre le bien pour un montant supérieur à sa valeur de reprise, générant ainsi une plus-value.** En résumé, la LOA est un type de financement locatif offrant une option d'achat, combinant les avantages de la location et la possibilité d'acquisition, tout en permettant une gestion flexible des biens à usage personnel ou professionnel.
Avantage pour le client : Ne pas se préoccuper de la revente du bien, donc de sa dépréciation au cours du temps.	Avantage pour le client : Gestion flexible, combinant les avantages de la location (LDD) et la possibilité d'acquisition (crédit conso).

Introduction

Comparatif des types de financement

		Crédit-bail	
	Crédit	**Location longue durée (LLD)**	**Location avec option d'achat (LOA)**
	Exemple sur une voiture neuve qui coûte 30 000€. Prix de la voiture neuve = 30 000€		
Financement	Montant du prêt : 28 000€ Apport : 2 000€ Durée du prêt : 4 ans TAEG : 3,5% Mensualité : 626€	Durée du leasing : 4 ans Acompte initial : 2 000€ Mensualité : 450€	Durée du leasing : 4 ans Acompte initial : 2 000€ Mensualité : 475€ Option d'achat à la fin du contrat : 12 000€
Coût total	Mensualités : 626 x 48 mois = 30 048 Total d'intérêts : 30 048 – 28 000 = 2 048 **Coût total :** 2 000 + 30 048 = **32 048**	Mensualités : 450 x 48 mois = 21 600 **Coût total** : 2 000 + 21 600 = **23 600**	Mensualités : 450 x 48 mois = 21 600 **Coût total *sans option d'achat*** : 2 000 + 21 600 = **24 800** **Coût total *avec achat*** : 23 600 + 12 000 = **35 600**
Conclusion	La solution la plus **économique** si le client prévoit de garder le véhicule En revanche, la mensualité est plus élevée par rapport au leasing. Moins accessible si la **capacité d'emprunt** est faible.	La mensualité est plus faible et donc plus accessible par rapport à un financement par crédit. **Economique** si le client ne souhaite pas devenir propriétaire de l'équipement. Sans possibilité d'être propriétaire du véhicule. Le véhicule doit être rendu au bailleur à la fin du contrat de location	Plus **coûteux** au global par rapport au financement par crédit. En revanche, l'effort mensuel est moindre et plus accessible. **Flexibilité** à la fin du contrat entre acheter et devenir propriétaire ou rendre le véhicule au bailleur. Le client pourra acheter le véhicule de mêmes caractéristiques sur le marché d'occasion si le prix est inférieur au prix d'option d'achat proposé par le bailleur.

Sommaire

Intégration du Machine Learning et du Risque Climatique dans la Tarification du Crédit-Bail

- Introduction au crédit-bail
- **Modélisation classique**
- Intégration du machine learning
- Intégration du risque climatique

Introduction

La valeur résiduelle

La valeur résiduelle est au cœur de la tarification des contrats de leasing.

Généralement, la durée d'utilisation du véhicule est très inférieure à sa durée de vie. Donc à la fin du contrat de leasing, le propriétaire peut espérer le revendre, le prix de revente est appelé valeur résiduelle.
A la fin des contrats, si le bien est remis à la vente sur le marché secondaire, la valeur résiduelle estimée par la banque sera confrontée au prix de marché.

La décote donne le prix futur du véhicule :

$$V_t = (1 - Decote(t)) \times V_0$$

Avec V_0 la valeur initiale du bien en location et V_t la valeur future du bien.

Pour obtenir la valeur résiduelle estimée, il suffira d'utiliser la décote estimée des biens en passant par les **courbes de décote**.

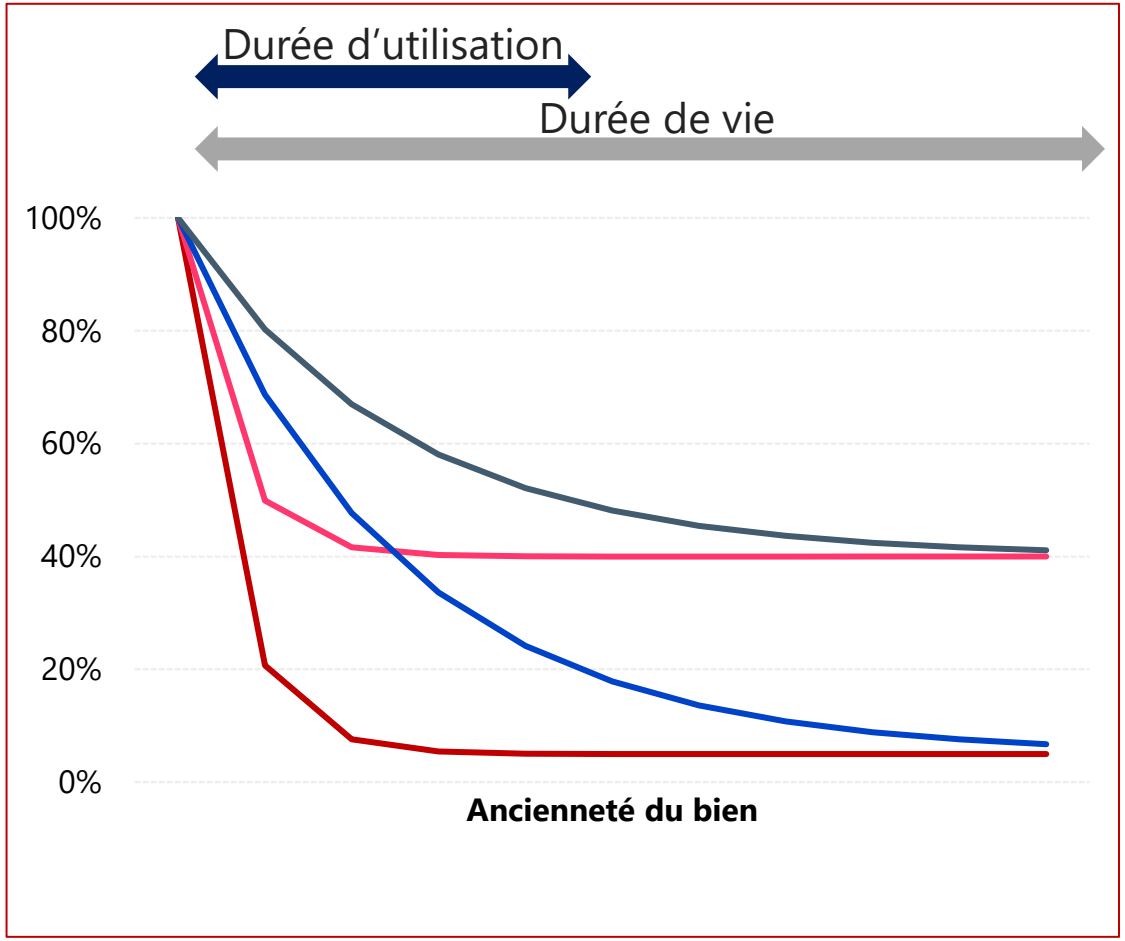

Exemple : Plusieurs exemples de dépréciations

Introduction

La décote

De façon intuitive, on observe en général plusieurs types de familles de décote.

- **A** : Dépréciation très rapide (ordinateurs, imprimantes…). La valeur résiduelle est proche de zéro. C'est un actif qu'il ne faudra pas stocker longtemps à la fin du contrat de leasing et il faudra inciter le client à récupérer cet actif à la maturité du contrat de leasing.
- **B** : Rapide en début de période puis conservation d'une valeur intrinsèque élevée tout au long de leur vie jusqu'à maturité. (exemple : une voiture haut de gamme perdra entre un et deux tiers de sa valeur les premières années de sa vie, mais gardera toujours une valeur élevée à long terme.
- **C** : Dépréciation plutôt lente et valeur résiduelle très faible à long terme.
- **D** : Dépréciation lente, conserve une valeur résiduelle élevée.

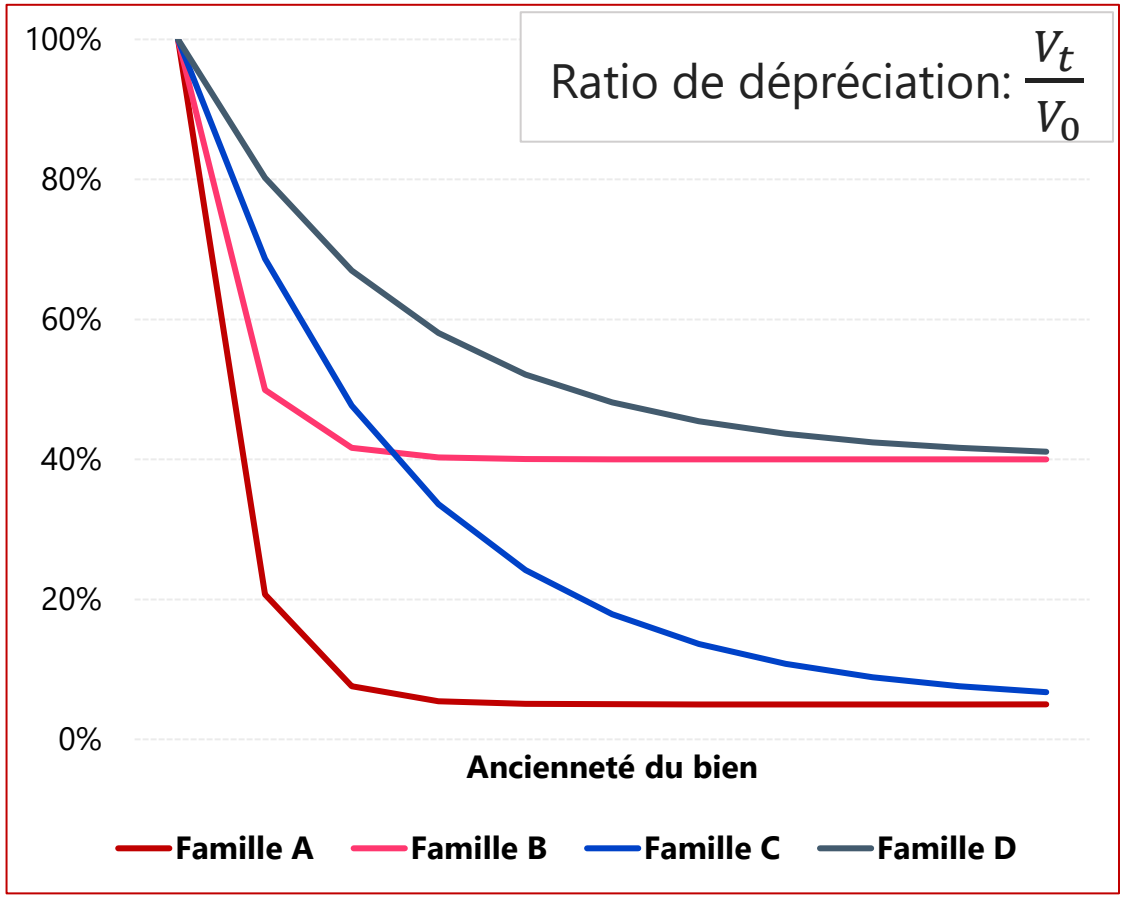

Tout l'enjeu se trouve donc dans l'estimation de la courbe de décote. Il faut attribuer un pattern de décote à chaque actif loué. **La vitesse de dépréciation** est au cœur de l'estimation de la décote.

$$*Decote(t) = 1 - \frac{V_t}{V_0}$$

Modélisation classique

Estimation de la décote

L'objectif de la modélisation statistique de la décote est d'estimer, pour un véhicule donné, la valeur résiduelle attendue à un horizon donné, à partir de son usure et ses caractéristiques techniques.
Segmentation métier de véhicules : Après avoir regroupé les véhicules dont les caractéristiques techniques sont proches (marque, type de carburant, type de moteur…), le modèle paramétrique visera à modéliser la décote

Hypothèses métiers

La modélisation classique de la décote repose sur plusieurs hypothèses largement validées empiriquement :

- Monotonie = la valeur décroit avec le temps
- Convexité = la dépréciation est rapide en début de vie puis ralentit avec l'âge.
- Stabilité = la dynamique moyenne de décote est stable dans le temps.

Approche paramétrique

Choix de l'approche paramétrique à travers la décroissance exponentielle:

$$V(t) = V_0 \times e^{-kt}$$

Avec k le taux de décote annuel

En découle directement :

$$Decote(t) = 1 - \frac{V_t}{V_0} = 1 - e^{-kt}$$

Lors de l'estimation paramétrique, une attention particulière doit être portée sur les outliers qui doivent être traités.

Estimation du paramètre

Transformation logarithmique pour rendre de la variable cible linéaire et ainsi estimer une régression linéaire:

$$ln\left(\frac{V_t}{V_0}\right) = \alpha + \beta_k \times t + \varepsilon$$

- α significativement proche de 0 car $ln\left(\frac{V_0}{V_0}\right) = ln(1) = 0$.
- $\beta_k = -\mathrm{k}$ mesure la vitesse de dépréciation du bien. Plus β_k est élevé plus la décote est rapide.
- ε représente la volatilité du marché.

Modélisation classique

Estimation de la décote - Limites

La **segmentation métier de véhicules** dont les caractéristiques techniques sont proches (marque, nombre de sièges, type de carburant) compromet l'approche paramétrique. La flotte de véhicule est scindée en groupes de voitures et chaque groupe devrait obtenir un modèle à part entière avec un paramètre k. Plusieurs limites découlent de ce phénomène :

Limite 1 : Hypothèses non respectées

Les hypothèses peuvent souvent êtes invalidées. Par exemple les courbes de décotes observées peuvent être non convexe, non monotone voire incomplètes.

Limite 2 : La création des groupes fragmente la flotte de véhicules

Le regroupement provoque inévitablement l'apparition de groupes contenant peu d'observations sur chaque année → **échantillon non représentatif / effectif faible**.

Multiplication du nombre de modèles

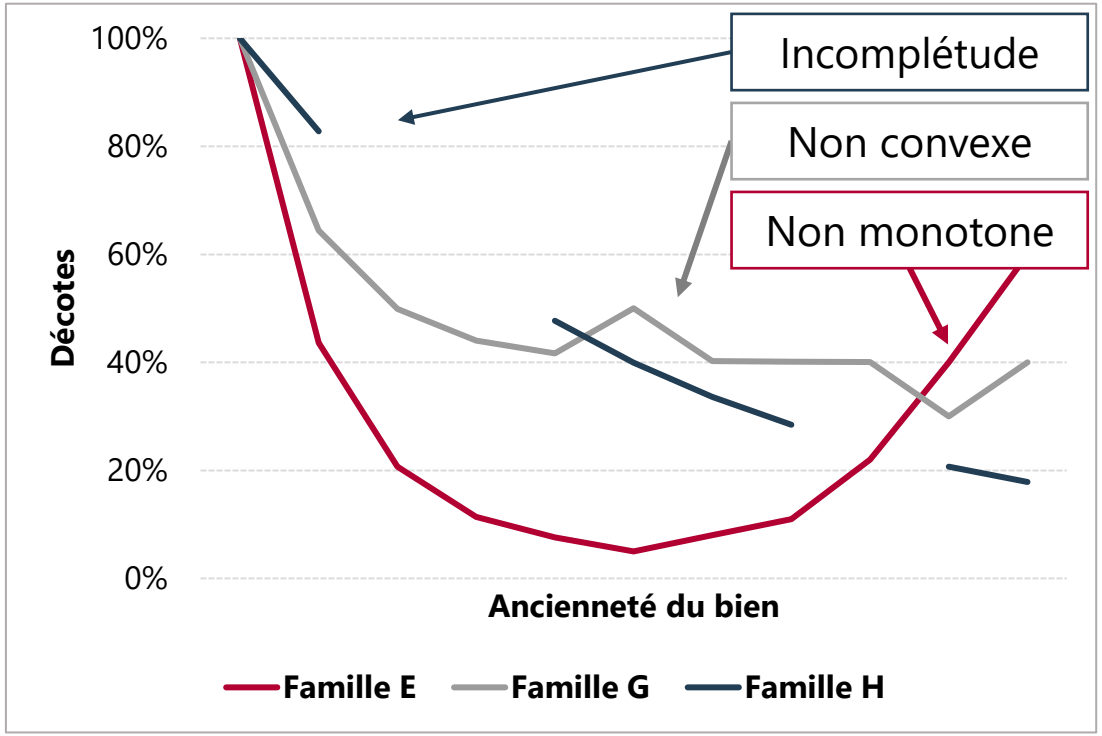

L'intégration du **Machine Learning** peut permettre de résoudre ses limites ou de les contourner.

Modélisation classique

Estimation de la décote – Limites : exemples

Convexité/Monotonie

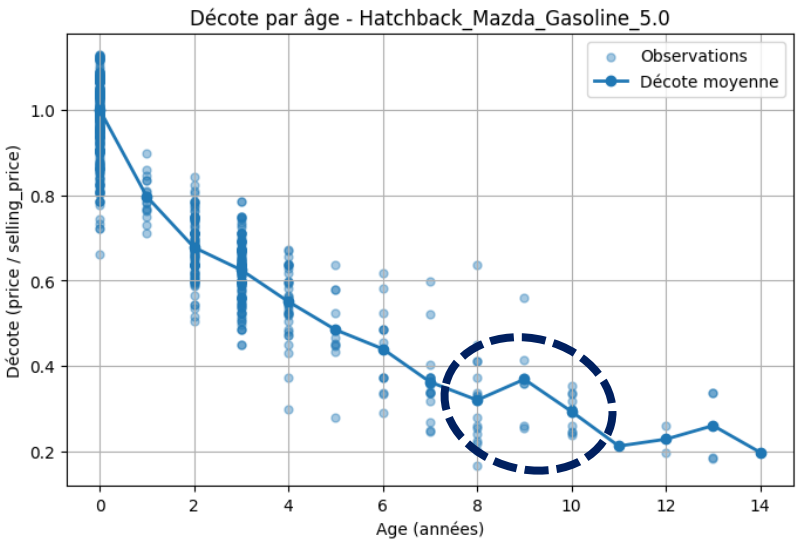

Incomplétude

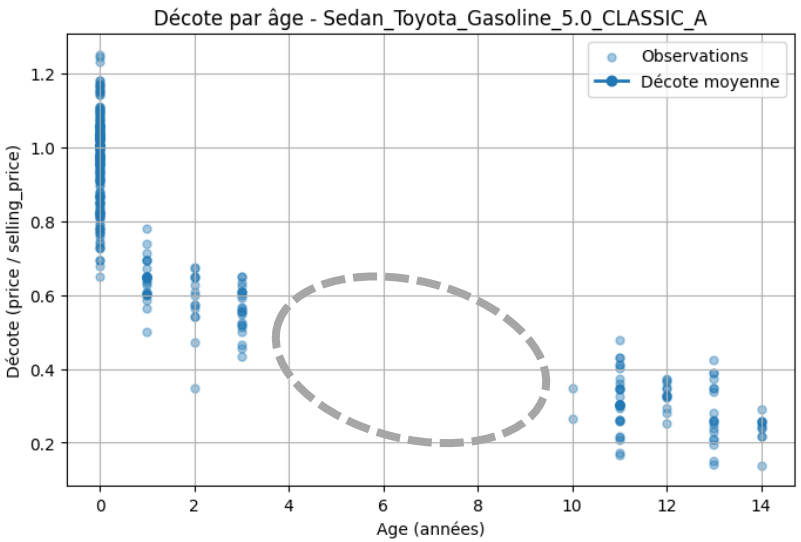

Non monotone

La convexité est régulièrement respectée dès lors qu'on supprime les voitures très âgées (voitures de collection). En effet, les courbes deviennent non convexes si un groupe de voiture prend de la valeur en devenant rare. La convexité est facile à obtenir, il suffit de filtrer sur des âges cohérent avec la problématique du leasing (un contrat dure 5 ans, nul besoin de faire un modèle qui capture le comportement de décote au-delà de 10 ou 15 ans)

Exemple sur un regroupement par :
Type de voiture, marque concessionnaire, carburant, nombre de siège, couleur (classique ou non), type de transmission, nombre de cylindres, longueur, puissance du moteur.

Sommaire

Intégration du Machine Learning et du Risque Climatique dans la Tarification du Crédit-Bail

- Introduction au crédit-bail
- Modélisation classique
- **Intégration du Machine Learning**
- Intégration du risque climatique

Intégrer le machine learning à la VR : 1ère étape

Retraiter les données : Traitement des outliers

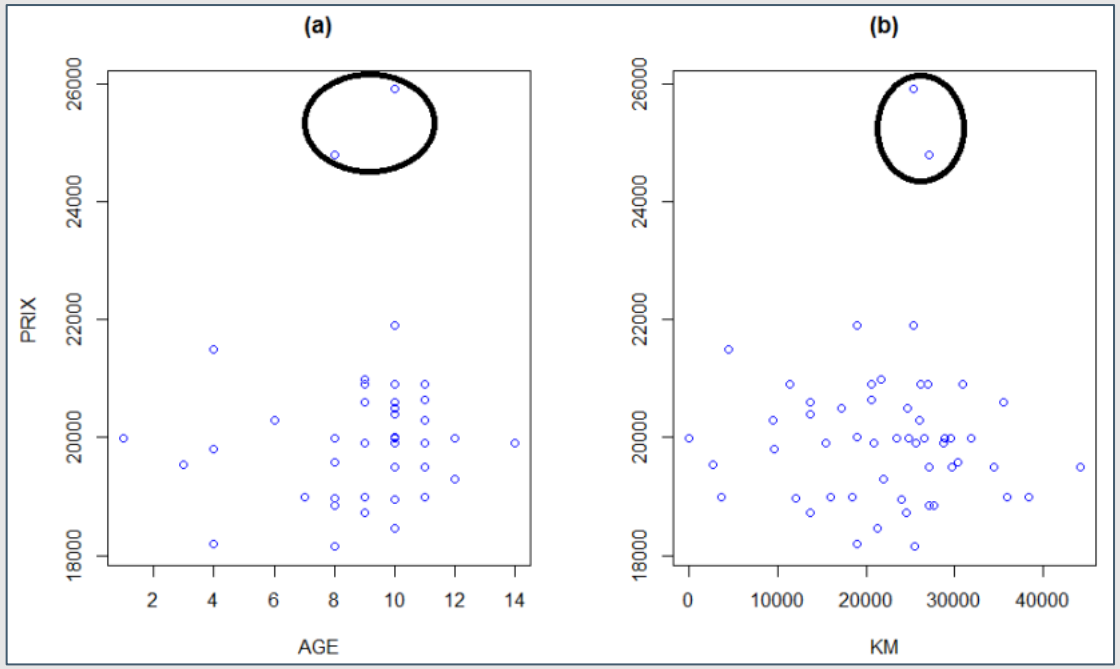

Des observations se démarquent significativement des autres en présentant une discordance dans la relation entre le prix du véhicule et son âge (a) et son kilométrage (b).

S-F Dimby : Detection d'outliers. Modélisation et prédiction (...) véhicules d'occasion. Thèse, Panthéon-Sorbonne, 2015.

Modélisation ML : CatBoost Quantile

CatBoost implémente la régression quantile dans un cadre de gradient boosting sur arbres de décision. Le modèle approxime la fonction cible comme une somme additive de fonctions faibles :

- La régression quantile vise à estimer la distribution conditionnelle d'une variable cible en fonction de covariables. Méthode qui se prête aux distributions asymétriques et outliers comme c'est le cas ici.

Une fonction Q_τ ($\tau \in (0,1)$) est définie pour obtenir la proba : $P(Y \leq Q_\tau(Y|X)) = \tau$

Son application dans le catboosting se traduit par la forme : $Q_\tau = sum(f_m(X))$

Où les f_m sont des arbres de décisions peu profonds.

Intégrer le machine learning à la VR : 2ème étape

Limites 1 - hypothèses non respectées : Retraiter les données des groupes

Retraitement des groupes incomplets ou non monotones réalisé à travers trois étapes centrales :

Bootstapping

- Création d'échantillons pour chaque segment de véhicules

Régression isotonique

- Pour chaque échantillon, estimer une régression non paramétrique isotonique → Prédiction ensuite pour chaque « âge » d'une décote monotone.

Il s'agit d'une correction des irrégularités observées (années manquantes, non-monotonie locale), à travers l'estimation d'une régression isotonique décroissante par groupe de véhicules, garantissant une décote moyenne monotone en fonction de l'âge. Cette étape ne résout pas la convexité non stricte qu'il conviendra de lisser.

Interpolation quadratique - Spline

- Pour s'approcher d'une convexité stricte, cohérente avec les hypothèses économiques de dépréciation, une spline de lissage quadratique est ajoutée sur les prédictions de la régression

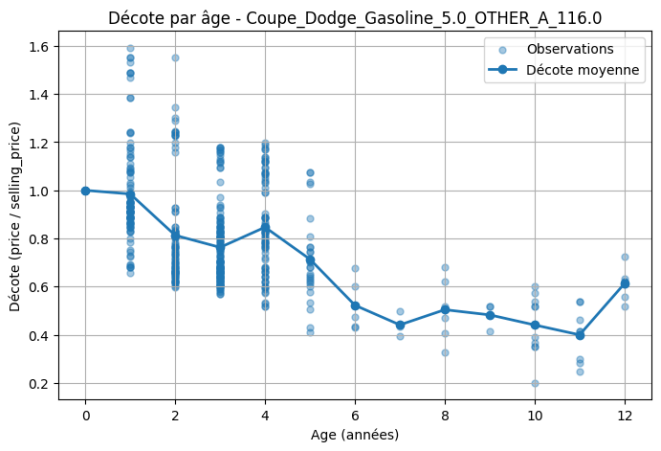

Courbe de décote observée

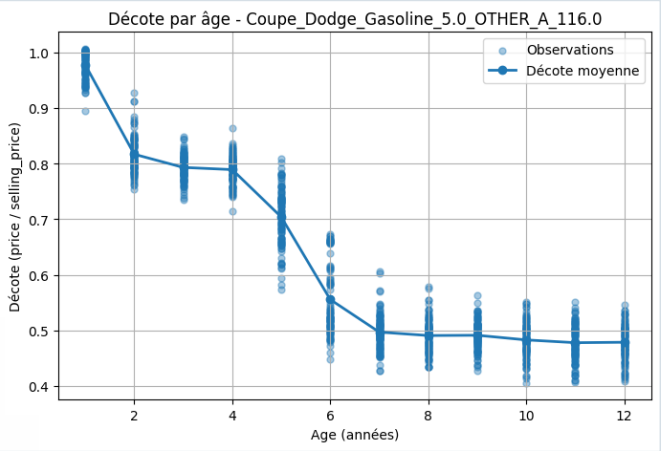

Courbe de décote corrigée

Intégrer le machine learning à la VR : 3ème étape

Limites 2 – Fragmentation de la flotte auto : Familles de dépréciation

Limite 2 : La création des groupes fragmente la flotte de véhicules

Le regroupement provoque inévitablement l'apparition de groupes contenant peu d'observations sur chaque année → **échantillon non représentatif / effectif faible**.

Multiplication du nombre de modèles

Solution ML :

Clustering de familles de dépréciation: Rassembler des groupes homogènes pour créer des familles de dépréciations, en fonction des vecteurs de paramètres de régressions de décote.

Résumé de l'approche proposée :

1. Créer les segments métiers des voitures, puis retraiter les données pour permettre la validation des hypothèses.

2. Estimation économétrique : Une fois les estimés, chaque groupe est caractérisé par un vecteur (α_g, k_g^1, k_g^2)

$$ln\left(\frac{V_{g,t}}{V_{g,0}}\right) = \alpha_g + k_g^1 \times Age_t + k_g^2 \times Kilometrage_t + \varepsilon$$, avec g un groupe donné.

3. Les vecteurs de paramètres de dépréciation marginal obtenus sont utilisés pour construire des familles de décotes avec un **algorithme de clustering** tel qu'un k-means. On passe alors de plusieurs centaines de groupes de voitures à une poignées de familles de dépréciation homogènes en courbe de décote d'âge et de kilométrage.

4. Modélisation paramétrique finale par famille : $ln\left(\frac{V_{f,t}}{V_{f,0}}\right) = \alpha_f + k_f \times Age_t + \varepsilon$.

Intégrer le machine learning à la VR : CatBoost

Un modèle global contenant les éléments économiques et les générations

Article de recherche, modélisation d'un modèle unique pour prédire la VR à l'aide de modèles ML.
A.Ghibellini et al. : A Comprehensive Approach to Residual Value. Analysis in the Luxury Automotive Market. University of Bologna, 2024.

Changements sur les distributions de valeurs résiduelles expliquées par le COVID-19 :

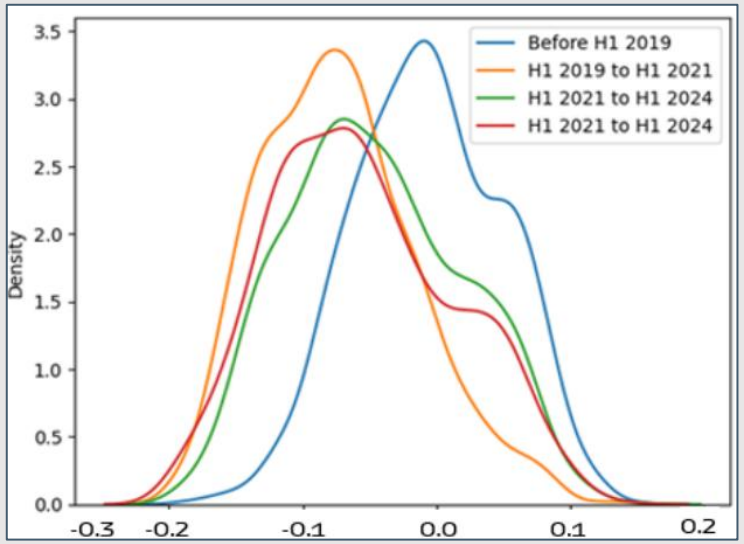

La distribution de la valeur résiduelle a évolué au fil des années, indiquant que des facteurs externes influencent cette métrique. Des variables économiques pourraient donc contribuer à expliquer la VR.

Modélisation ML : CatBoost

Plusieurs modèles sont testés dans l'article, le CatBoost minimise le MAPE. En analysant la contribution des variables on remarque que les variables importantes sont : le type de modèle de voiture, l'emplacement géographique, l'âge du véhicule, l'inflation, le chômage et l'ancienneté du modèle.

Ici, un seul modèle pour l'ensemble de la flotte de voiture est entrainé. Sans paramètre de décote.

Cependant il est intéressant de noter la présence de l'ancienneté du modèle : permettant d'évaluer le risque de génération du modèle.

Intégrer le machine learning à la VR : Alternative

Modèles ML robustes de prédiction et d'interprétation

A.Ghibellini et al. proposent un modèle global pour estimer la décote et ensuite prédire. Ils proposent d'estimer directement des arbres de décisions sur une flotte qui est totalement diverse, mise à part qu'elle est constituée de Ferrari dans leur cas. Mais des différences techniques sont encore visibles (type de voiture, nombre de cylindres…).

Dans un contexte plus large de leasing (plusieurs marques, plusieurs gammes), il serait plutôt intéressant de commencer par regrouper en familles de dépréciation les voitures (comme expliqué plus tôt).
Une fois que les familles sont constituées, un modèle ML peut être envisagé pour estimer la VR au sein de chaque famille.

$$V(t) = V_0 \times e^{-kt}$$

Avec k comme variable cible, en réécrivant tel que :

$$k = -\frac{1}{t} ln\left(\frac{V_t}{V_0}\right)$$

Un k par véhicule (transaction de vente) est observé. Un modèle peut donc chercher à estimer le taux de décote

Modélisation ML : CatBoost

Puisque *A.Ghibellini et al.* obtiennent que CatBoost permet de minimiser le critère MAPE, ce modèle paraît adéquat pour prédire k.

Une fois que les familles de dépréciations sont créées et rassemble plusieurs $groupes_i$. Les caractéristiques techniques ne sont plus intéressantes à mettre dans le modèle. Reste les variables d'usure (comme le kilométrage).

$$k_i = f(groupe_i, kilometrage_i, variables\ macro)$$

Ceci permettra d'obtenir des taux de décote plus précis.

De plus le taux de décote annuel est fonction de variables économiques, ce qui rend possible l'intégration du risque climatique.

Cette approche permet de lier un pattern de dépréciation en fonction de caractéristiques techniques, de variables d'usure et de variables économiques tout en restant dans un cadre interprétable avec k qui reste défini.

Sommaire

Intégration du Machine Learning et du Risque Climatique dans la Tarification du Crédit-Bail

- Introduction au crédit-bail
- Modélisation classique
- Intégration du Machine Learning
- **Intégration du risque climatique**

Intégrer le risque climatique aux modèles de leasing

Finance, climat et crédit-bail

Les institutions financières sont tenues d'identifier et de mesurer les risques climatiques dans leurs dispositifs de gestion des risques, notamment dans le cadre de l'**ICAAP** et des **exercices de stress tests** réglementaires. Ces dispositifs permettent d'évaluer l'impact des chocs de transition et physiques sur la valorisation des actifs détenus.

Variation des niveaux d'émissions CO2 par secteur dans l'UE :

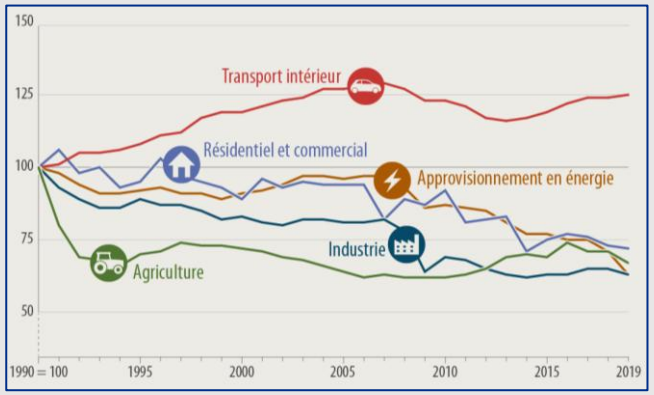

Risque de transition

- Impact des changements obligatoires pour atteindre des objectifs climatiques (ex : la neutralité carbone)
- Le secteur automobile est très impacté par ce risque puisque ce secteur est responsable de 25% des émissions CO2 en Europe (source : parlement européen). Donc il doit s'adapter en transitionnant vers une économie dite plus verte. En attendant de migrer vers de l'électrique ou de l'hybride, le parc automobile existant est sujet à un risque de dépréciation rapide.

Risque physique

- Chocs chroniques/aigus (tempête, inondation/hausse des températures…).
- Intervention des frais pendant la durée de vie du contrat (le véhicule subit un choc climatique). Donc le bailleur subit des risques plus grands. De plus, il cherchera à se couvrir fortement à travers son assurance ce qui augmentera ses frais d'assurance et diminuera sa marge.

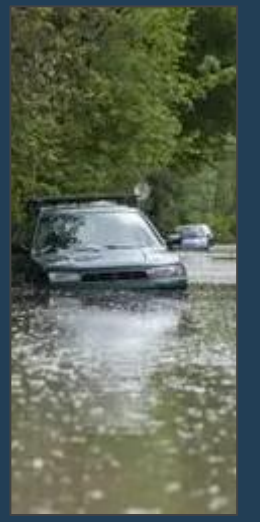

Intégrer le risque climatique aux modèles de leasing

Risque climatique de crédit : delta de PD

Objectif : Impacter la note de PD en stressant le brent et donc attribuer un nouveau taux de PD, soit un calcul à nouveau sur l'ECL. La différence entre l'ECL et l'ECL climatique stressé, donné par le delta en PD pour chaque contrepartie, est l'aboutissement de ces calculs.

Coût du carburant

Approximation pour des particuliers/professionnels:

$$Coût\ du\ carburant\ annuel = \sum \frac{M}{100} \times Conso_v^{L/100km} \times Prix\ du\ carburant \times A$$

Avec M le nombre moyen de kilomètres parcourus en moyenne en France,
$Conso_v^{L/100km}$ la consommation d'essence pour une voiture v (nombre de litres pour parcourir 100 kilomètres),
A le nombre moyen d'années de détention de la voiture par un nouvel acheteur (en France $A = 10\ ans$)

Scénario Brent (USD/baril)

Prix moyen/an

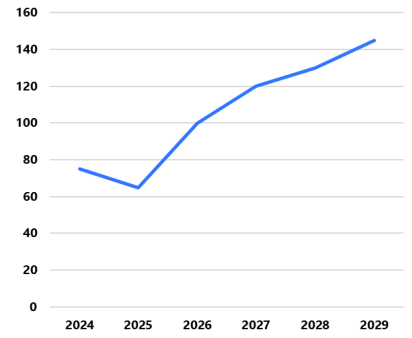

Canaux de transmission vers le RISQUE DE CREDIT

Hausse des coûts

Impact négatif sur les contreparties

Trésorerie, épargne disponible, …

Stress du score de notation

Renotation : AA+ → BBB

PD Stressée

Intégrer le risque climatique aux modèles de leasing

Risque climatique de VR : Un stress extrême sur la valeur de revente

Un moyen de stresser la valeur résiduelle serait de soustraire à la valeur future estimée, un coût d'opportunité pour un acheteur potentiel d'acheter une voiture plutôt qu'une autre. L'hypothèse ici est que l'acheteur paiera moins cher une voiture si elle est très consommatrice en essence sachant que dans un scénario de transition, le prix du pétrole augmente fortement. Le prix de marché des voitures consommatrice baissera alors.
Un exemple typique de stress-climatique est présenté ci-dessous : Deux coûts de carburants sont calculés, un avec un prix de carburant actuel, puis un deuxième avec un prix du carburant stressé. La différence entre ces deux coûts donne un delta climatique de coûts du carburant. Ensuite, la différence est soustraite à la valeur future de la voiture.

Coût du carburant

Approximation pour des particuliers/professionnels:

$$Coût\ du\ carburant\ total = \sum \frac{M}{100} \times Conso_v^{L/100km} \times Prix\ du\ carburant \times A$$

Avec M le nombre moyen de kilomètres parcourus en moyenne en France,
$Conso_v^{L/100km}$ la consommation d'essence pour une voiture v (nombre de litres pour parcourir 100 kilomètres),
A le nombre moyen d'années de détention de la voiture par un nouvel acheteur (en France $A = 10\ ans$)

Scénario Brent (USD/baril)

Prix moyen/an

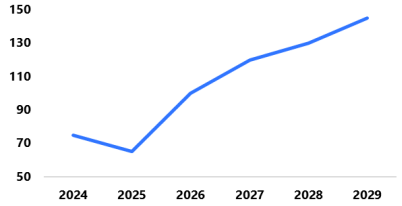

Exemple numérique

Exemple d'une voiture essence SP:
Prix futur estimé = 25K
Conso=9,5L/100

Stress sur le prix du baril

Brent ($)
Prix observé en 2024 : $75
Prix stressé horizon 4 ans : $147
Soit une hausse de **+196%**

Carburant sans plomb (€)
Prix observé en 2024 : 1,7€
Stress sur le prix du carburant :
Prix stressé horizon 4 ans : 3,3€

Coûts
$Coût\ carb^{Base} = 20K$
$Coût\ carb^{Stress} = 38K$
$Delta\ climatique = \mathbf{18K}$

Prix futur estimé stressé = 25K – 18K = 7K

Valeur estimée flotte automobile = 45 985 millions

Valeur estimée ***stressée*** flotte automobile = **16 483 millions €**

Intégrer le risque climatique aux modèles de leasing

Plusieurs approches (non exhaustives)

Approche 1 : Projeter le glissement de l'indice des prix des voitures mensuel à l'aide d'un modèle ML de **gradient boosting**. Les variables candidates seront des variables économiques, des variables financière…

$$\boldsymbol{Inflation^{voitures} = f(macro, indices\ financiers\ \ldots)} \quad (1)$$

Intégrer ensuite un scénario climatique stressé pour obtenir l'indice des prix stressé. Ce qui permet de constituer un delta par rapport à l'indice réel

$$\boldsymbol{Delta^{stress\ climatique}} = \Delta(\boldsymbol{Inflation^{voitures}}, \boldsymbol{Inflation^{voitures}} \quad (2)$$

Finalement, les prix des voitures V(t) peuvent être stressés d'autant que l'indice est perturbé par le scénario climatique :

$$\boldsymbol{V(t)^{Stress} = V_0 \times e^{-kt} \times Delta^{stress\ climatique}} \quad (3)$$

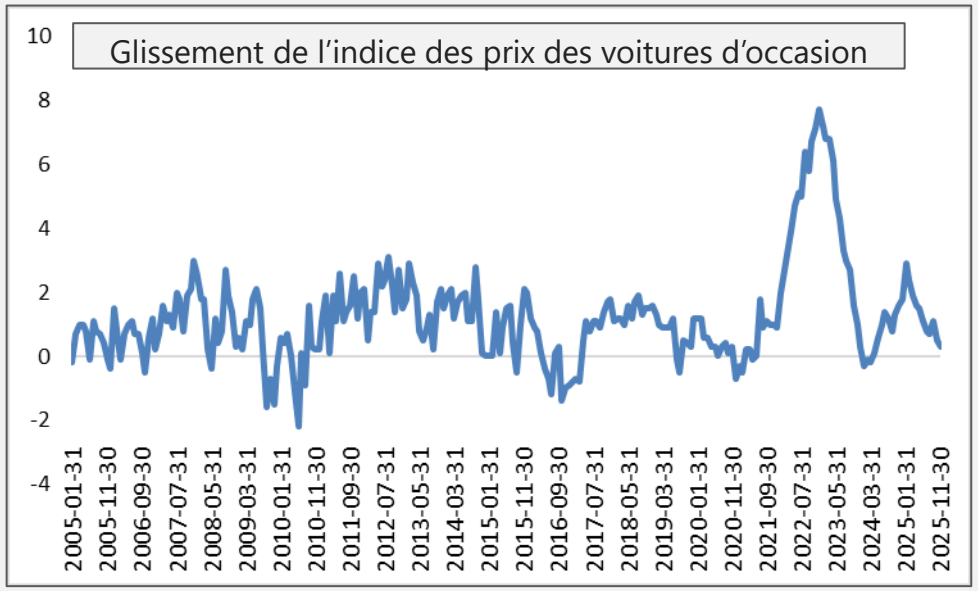

Glissement en France :
https://webstat.banque-france.fr/fr/catalogue/icp/ICP.M.FR.N.071100.4.ANR
Et en Zone Euro :
https://webstat.banque-france.fr/fr/catalogue/icp/ICP.M.U2.N.071100.4.ANR

Approche 2 : Utiliser les scénarios de stress-test climatiques comme input prédictif au modèle l'indice des prix qui devient stressé modèle globale **CatBoost** proposé par l'article de A.Ghibellini et al.

Intégrer le risque climatique aux modèles de leasing

Plusieurs approches (non exhaustives)

Approche 3 : Faire des dégradations de prix de voitures à partir de l'ancienneté et de la conformité réglementaire du véhicule. Les réglementations en France et en Europe se durcissent, comme par exemple à travers les « crit'air » qui empêcherait des véhicules polluants à circuler . Ceci rend provoque la dépréciation totale de voitures d'anciennes génération (celles qui ne passent plus les normes). Ceci provoque une dépréciation plus marquée sur les voitures anciennes restantes en circulation.

Approche 4 : Faire une VaR à partir des éléments du modèle ML qui prend la forme :

$$\boldsymbol{k_i = f(groupe_i, kilometrage_i, variables\ macro)}$$

Références scientifiques

Publications

S-F Dimby : Detection d'outliers. Modélisation et prédiction. Application aux données de véhicules d'occasion. Thèse, Panthéon-Sorbonne, 2015.

A.Ghibellini et al. : A Comprehensive Approach to Residual Value. Analysis in the Luxury Automotive Market. Article IEEE Access, University of Bologna, 2024

S.Bergmann and S.Feuerriegel : Machine learning for predicting used car resale prices using granular vehicle equipment information. ETH Zurick, 2025.

S.Prado et V.Mignon : Le Risque de Valeur Résiduelle : trois études quantitatives. Thèse, Nanterre, 2010